Header print("Name: \t\t{}".format(myName)) print("NIM: \t\t{}".format(myNIM)) print("Start: \t\t{}".format(myDate)) print("Device ID: \t{}".format(myDevice)) Name: Reinhard Javera Maheswara NIM: Start: 2024-09-01 22:08:51.660811 18fe9874-6874-11ef-9c3d-d33627ff6c48 Device ID: Hasil kerja In [488... import pandas as pd print("Pandas version: {}". format(pd.__version__)) Pandas version: 2.2.2 In [489... import matplotlib as mp print("Matplotlib version: {}". format(mp.__version__)) Matplotlib version: 3.8.4 In [490... import numpy as np print("Numpy version: {}".format(np.__version__)) Numpy version: 1.26.4

In [487... **import** datetime

import uuid

myNIM = "77732"

Fill in your name and NIM

myName = "Reinhard Javera Maheswara"

myDate = datetime.datetime.now() myDevice = str(uuid.uuid1())

In [491... import scipy as sp print("Scipy version: {}".format(sp.__version__)) Scipy version: 1.13.1 In [492... **import** sklearn print("Scikit-learn version: {}".format(sklearn.__version__)) Scikit-learn version: 1.4.2 In [493... **from** sklearn.datasets **import** load_iris iris_dataset = load_iris() .. _iris_dataset:

TUGAS LAB IF540 MACHINE LEARNING

WEEK [01]: [Pengenalan Dasar Pembelajaran Mesin]

Semester Ganjil 2022/2023

In [494... print(iris_dataset['DESCR'][:193]+"\n...") Iris plants dataset -----**Data Set Characteristics:** :Number of Instances: 150 (50 in each of three classes) :Number of Attributes: 4 numeric, predictive In [495... print("Target: {}".format(iris_dataset['target_names'])) Target: ['setosa' 'versicolor' 'virginica'] In [496... | print("Feature: {}".format(iris_dataset['feature_names'])) Feature: ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)'] In [497... print("Shape: {}".format(iris_dataset['data'].shape)) Shape: (150, 4) In [498... print("Type: {}".format(type(iris_dataset['data']))) Type: <class 'numpy.ndarray'> In [499... print("First five:\n {}".format(iris_dataset['data'][:5])) First five: [[5.1 3.5 1.4 0.2]

[4.9 3. 1.4 0.2] [4.7 3.2 1.3 0.2] [4.6 3.1 1.5 0.2] [5. 3.6 1.4 0.2]] In [500... print("Type of target: {}".format(type(iris_dataset['target']))) Type of target: <class 'numpy.ndarray'> In [501... print("Target shape: {}".format((iris_dataset['target'].shape))) Target shape: (150,) In [502... print("Target data: {}".format(iris_dataset['target'])) 2 2] In [503... **from** sklearn.model_selection **import** train_test_split X_train, X_test, y_train, y_test = train_test_split(iris_dataset['data'], iris_dataset['target'], random_state = 0) In [504... print("X_train shape: {}".format(X_train.shape)) print("y_train shape: {}".format(y_train.shape)) print("X_test shape: {}".format(X_test.shape)) print("y_test shape: {}".format(y_test.shape)) X_train shape: (112, 4) y_train shape: (112,) X_test shape: (38, 4) y_test shape: (38,) grr = pd.plotting.scatter_matrix(iris_dataframe, c=y_train, figsize=(15,15), marker='o', hist_kwds={'bins':20}, s=60, alpha=.8) 7.5 7.0

In [505... iris_dataframe = pd.DataFrame(X_train, columns=iris_dataset.feature_names) length 4.0 petal length (cm) petal width (cm) 1.5 petal length (cm) petal width (cm) sepal length (cm) knn = KNeighborsClassifier(n_neighbors=1) KNeighborsClassifier KNeighborsClassifier(n_neighbors=1) print("X_new.shape: {}".format(X_new.shape)) X_new.shape: (1, 4) print("Prediction: {}".format(prediction)) print("Predicted target: {}".format(iris_dataset['target_names'][prediction])) Prediction: [0] Predicted target: ['setosa'] print("Test set predictions:\n {}".format(y_pred)) Test set predictions: $[2 \ 1 \ 0 \ 2 \ 0 \ 2 \ 0 \ 1 \ 1 \ 1 \ 2 \ 1 \ 1 \ 1 \ 1 \ 0 \ 1 \ 1 \ 0 \ 0 \ 2 \ 1 \ 0 \ 0 \ 2 \ 0 \ 0 \ 1 \ 1 \ 0 \ 2 \ 1 \ 0 \ 2 \ 2 \ 1 \ 0$ 2] print("Test set score: {:.2f}".format(knn.score(X_test, y_test))) Test set score: 0.97 wine_dataset = load_wine()

In [506... **from** sklearn.neighbors **import** KNeighborsClassifier In [507... knn.fit(X_train, y_train) Out[507... In [508... X_new = np.array([[5, 2.9, 1, 0.2]]) In [509... prediction = knn.predict(X_new) In [510... y_pred = knn.predict(X_test) In [511... # print("Test set score: {:.2f}".format(np.mean(y_pred == y_test))) In [512... **from** sklearn.datasets **import** load_wine In [513... print(wine_dataset['DESCR'][:193]+"\n...") .. _wine_dataset: Wine recognition dataset -----**Data Set Characteristics:** :Number of Instances: 178 :Number of Attributes: 13 numeric, predictive attributes and the c In [514... | print("Target: {}".format(wine_dataset['target_names'])) Target: ['class_0' 'class_1' 'class_2'] In [515... | print("Feature: {}".format(wine_dataset['feature_names'])) Feature: ['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium', 'total_phenols', 'nonflavanoid_phenols', 'proanthocyanins', 'color_intensity', 'hue', 'od280/od315_of_diluted_wines', 'proline'] In [516... print("Shape: {}".format(wine_dataset['data'].shape)) Shape: (178, 13) In [517... | print("Type: {}".format(type(wine_dataset['data']))) Type: <class 'numpy.ndarray'> In [518... print("First five:\n {}".format(wine_dataset['data'][:5])) [[1.423e+01 1.710e+00 2.430e+00 1.560e+01 1.270e+02 2.800e+00 3.060e+00 2.800e-01 2.290e+00 5.640e+00 1.040e+00 3.920e+00 1.065e+03] [1.320e+01 1.780e+00 2.140e+00 1.120e+01 1.000e+02 2.650e+00 2.760e+00 2.600e-01 1.280e+00 4.380e+00 1.050e+00 3.400e+00 1.050e+03] [1.316e+01 2.360e+00 2.670e+00 1.860e+01 1.010e+02 2.800e+00 3.240e+00 3.000e-01 2.810e+00 5.680e+00 1.030e+00 3.170e+00 1.185e+03] [1.437e+01 1.950e+00 2.500e+00 1.680e+01 1.130e+02 3.850e+00 3.490e+00 2.400e-01 2.180e+00 7.800e+00 8.600e-01 3.450e+00 1.480e+03] [1.324e+01 2.590e+00 2.870e+00 2.100e+01 1.180e+02 2.800e+00 2.690e+00 3.900e-01 1.820e+00 4.320e+00 1.040e+00 2.930e+00 7.350e+02]] In [519... print("Type of target: {}".format(type(wine_dataset['target']))) Type of target: <class 'numpy.ndarray'> In [520... print("Target shape: {}".format((wine_dataset['target'].shape))) Target shape: (178,) In [521... print("Target data: {}".format(wine_dataset['target'])) In [522... **from** sklearn.model_selection **import** train_test_split X_train, X_test, y_train, y_test = train_test_split(wine_dataset['data'], wine_dataset['target'], random_state = 0) In [523... print("X_train shape: {}".format(X_train.shape)) print("y_train shape: {}".format(y_train.shape)) print("X_test shape: {}".format(X_test.shape)) print("y_test shape: {}".format(y_test.shape)) X_train shape: (133, 13) y_train shape: (133,) X_test shape: (45, 13) y_test shape: (45,) In [524... wine_dataframe = pd.DataFrame(X_train, columns=wine_dataset.feature_names) grr = pd.plotting.scatter_matrix(wine_dataframe, c=y_train, figsize=(15,15), marker='o', hist_kwds={'bins':20}, s=60, alpha=.8)

proanthocyanins color_intensity

nonflavanoid_phenols

od280/od315_of_diluted_wings hue

total_phenols flavanoids

alcalinity_of_ash magnesium

alcohol malic_acid

In [525... **from** sklearn.neighbors **import** KNeighborsClassifier knn = KNeighborsClassifier(n_neighbors=1)

KNeighborsClassifier

KNeighborsClassifier(n_neighbors=1)

print("X_new.shape: {}".format(X_new.shape))

print("Prediction: {}".format(prediction))

In [531... **from** sklearn.datasets **import** load_breast_cancer

breast_cancer_dataset = load_breast_cancer()

In [532... print(breast_cancer_dataset['DESCR'][:193]+"\n...")

Breast cancer wisconsin (diagnostic) dataset -----

print("Test set predictions:\n {}".format(y_pred))

In [530... print("Test set score: {:.2f}".format(knn.score(X_test, y_test)))

In [533... | print("Target: {}".format(breast_cancer_dataset['target_names']))

In [534... | print("Feature: {}".format(breast_cancer_dataset['feature_names']))

'mean smoothness' 'mean compactness' 'mean concavity'

In [535... print("Shape: {}".format(breast_cancer_dataset['data'].shape))

In [536... | print("Type: {}".format(type(breast_cancer_dataset['data'])))

In [537... print("First five:\n {}".format(breast_cancer_dataset['data'][:5]))

Feature: ['mean radius' 'mean texture' 'mean perimeter' 'mean area'

'concave points error' 'symmetry error' 'fractal dimension error' 'worst radius' 'worst texture' 'worst perimeter' 'worst area' 'worst smoothness' 'worst compactness' 'worst concavity'

'worst concave points' 'worst symmetry' 'worst fractal dimension']

[[1.799e+01 1.038e+01 1.228e+02 1.001e+03 1.184e-01 2.776e-01 3.001e-01 1.471e-01 2.419e-01 7.871e-02 1.095e+00 9.053e-01 8.589e+00 1.534e+02 6.399e-03 4.904e-02 5.373e-02 1.587e-02 3.003e-02 6.193e-03 2.538e+01 1.733e+01 1.846e+02 2.019e+03 1.622e-01 6.656e-01 7.119e-01 2.654e-01

[2.057e+01 1.777e+01 1.329e+02 1.326e+03 8.474e-02 7.864e-02 8.690e-02 7.017e-02 1.812e-01 5.667e-02 5.435e-01 7.339e-01 3.398e+00 7.408e+01 5.225e-03 1.308e-02 1.860e-02 1.340e-02 1.389e-02 3.532e-03 2.499e+01 2.341e+01 1.588e+02 1.956e+03 1.238e-01 1.866e-01 2.416e-01 1.860e-01

[1.969e+01 2.125e+01 1.300e+02 1.203e+03 1.096e-01 1.599e-01 1.974e-01 1.279e-01 2.069e-01 5.999e-02 7.456e-01 7.869e-01 4.585e+00 9.403e+01 6.150e-03 4.006e-02 3.832e-02 2.058e-02 2.250e-02 4.571e-03 2.357e+01 2.553e+01 1.525e+02 1.709e+03 1.444e-01 4.245e-01 4.504e-01 2.430e-01

[1.142e+01 2.038e+01 7.758e+01 3.861e+02 1.425e-01 2.839e-01 2.414e-01 1.052e-01 2.597e-01 9.744e-02 4.956e-01 1.156e+00 3.445e+00 2.723e+01 9.110e-03 7.458e-02 5.661e-02 1.867e-02 5.963e-02 9.208e-03 1.491e+01 2.650e+01 9.887e+01 5.677e+02 2.098e-01 8.663e-01 6.869e-01 2.575e-01

[2.029e+01 1.434e+01 1.351e+02 1.297e+03 1.003e-01 1.328e-01 1.980e-01 1.043e-01 1.809e-01 5.883e-02 7.572e-01 7.813e-01 5.438e+00 9.444e+01 1.149e-02 2.461e-02 5.688e-02 1.885e-02 1.756e-02 5.115e-03 2.254e+01 1.667e+01 1.522e+02 1.575e+03 1.374e-01 2.050e-01 4.000e-01 1.625e-01

In [538... print("Type of target: {}".format(type(breast_cancer_dataset['target'])))

In [539... print("Target shape: {}".format((breast_cancer_dataset['target'].shape)))

Target data: [0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 0 0 0 0 0 0 0 0 0 0 0 0 0

X_train, X_test, y_train, y_test = train_test_split(breast_cancer_dataset['data'], breast_cancer_dataset['target'], random_state = 0)

grr = pd.plotting.scatter_matrix(breast_cancer_dataframe, c=y_train, figsize=(15,15), marker='o', hist_kwds={'bins':20}, s=60, alpha=.8)

1 0 0 0 0 0 0 0 1 0 1 1 1 1 1 1 0 0 1 0 0 1 1 1 1 1 0 0 1 0 0 1 1 1 1 0 0 0 0 0 1 1 1 1 1 0 1 0 0 0

In [543... breast_cancer_dataframe = pd.DataFrame(X_train, columns=breast_cancer_dataset.feature_names)

print("Predicted target: {}".format(breast_cancer_dataset['target_names'][prediction]))

Berikan simpulan yang dilakukan dari hasil kerja menggunakan algoritma dan 2 dataset yang dipilih. Simpulan bisa berkisar antara (bisa di modifikasi):

 $[1\ 1\ 1\ 0\ 1\ 1\ 1\ 1\ 1\ 1\ 0\ 1\ 1\ 1\ 0\ 0\ 1\ 0\ 0\ 0\ 0\ 1\ 1\ 1\ 0\ 1\ 1\ 1\ 1\ 0\ 1\ 0\ 1\ 0\ 1\ 0\ 1$

- Hasil akurasi yang diberikan (jika ada dalam modul)

- Hasil perbandingan akurasi antara algoritma (jika ada dalam modul)

- Hasil pemikiran dan observasi akhir dari kerja menurut mahasiswa.

Save the notebook, then convert the notebook to html (by running the next code).

In [551... !jupyter nbconvert --to html "./IF540L_H_laporan_M01_00000077732_Reinhard Javera Maheswara.ipynb" --output-dir="./"

[NbConvertApp] Converting notebook ./IF540L_H_laporan_M01_00000077732_Reinhard Javera Maheswara.ipynb to html

kemungkinan terjadinya overlap antar kelas, dapat membuat kNN kesulitan dalam melakukan prediksi yang akurat.

jumlah fitur, distribusi data dan kualitas fitur juga memainkan peran penting dalam efektivitas algoritma kNN.

kemungkinan terjadinya overlap antar kelas, dapat membuat kNN kesulitan dalam melakukan prediksi yang akurat.

jumlah fitur, distribusi data dan kualitas fitur juga memainkan peran penting dalam efektivitas algoritma kNN.

Model kNN mencapai akurasi tertinggi pada Iris Dataset dengan 97%, diikuti oleh Breast Cancer Dataset dengan 92%, dan Wine Dataset memiliki akurasi terendah dengan 76%. Perbedaan dalam tingkat akurasi ini mungkin disebabkan oleh variasi kompleksitas pada masing-masing dataset. Iris Dataset cenderung lebih sederhana dengan fitur yang lebih

sedikit dan kelas yang terpisah dengan jelas, sehingga memudahkan kNN dalam melakukan klasifikasi. Sebaliknya, Wine Dataset dengan jumlah fitur yang lebih banyak dan

Perbedaan akurasi yang terlihat pada ketiga dataset ini memberikan wawasan penting tentang bagaimana kompleksitas data mempengaruhi kinerja model kNN. Iris Dataset yang memiliki jumlah fitur yang sedikit dan kelas yang jelas terpisah menunjukkan bahwa kNN dapat bekerja dengan sangat baik ketika data memiliki struktur yang sederhana. Di sisi lain, Wine Dataset yang memiliki lebih banyak fitur menunjukkan bahwa kNN dapat mengalami kesulitan dalam menangani dataset dengan dimensi yang lebih tinggi dan potensi overlap antar kelas. Ini mungkin disebabkan oleh fakta bahwa kNN tidak melakukan pemrosesan fitur yang kompleks dan sangat bergantung pada metrik jarak yang dapat menjadi kurang efektif dalam ruang fitur yang lebih besar.

Selain itu, performa yang tinggi pada Breast Cancer Dataset meskipun jumlah fiturnya lebih banyak menunjukkan bahwa kNN masih dapat bekerja dengan baik pada data yang memiliki fitur yang informatif dan terstruktur dengan baik, meskipun kompleksitasnya lebih tinggi. Hal ini menegaskan bahwa selain

Ini juga membuka peluang untuk mengeksplorasi model lain yang mungkin lebih efektif dalam menangani dataset dengan kompleksitas yang lebih tinggi.

Dari hasil ini, kita bisa menyimpulkan bahwa kNN cenderung lebih cocok untuk dataset dengan fitur yang lebih sedikit dan kelas yang terpisah dengan jelas.

Untuk dataset yang lebih kompleks, mungkin diperlukan metode pra-pemrosesan data seperti pengurangan dimensi atau normalisasi untuk meningkatkan performa model kNN.

Model kNN mencapai akurasi tertinggi pada Iris Dataset dengan 97%, diikuti oleh Breast Cancer Dataset dengan 92%, dan Wine Dataset memiliki akurasi terendah dengan 76%. Perbedaan dalam tingkat akurasi ini mungkin disebabkan oleh variasi kompleksitas pada masing-masing dataset. Iris Dataset cenderung lebih sederhana dengan fitur yang lebih

sedikit dan kelas yang terpisah dengan jelas, sehingga memudahkan kNN dalam melakukan klasifikasi. Sebaliknya, Wine Dataset dengan jumlah fitur yang lebih banyak dan

Perbedaan akurasi yang terlihat pada ketiga dataset ini memberikan wawasan penting tentang bagaimana kompleksitas data mempengaruhi kinerja model kNN. Iris Dataset yang memiliki jumlah fitur yang sedikit dan kelas yang jelas terpisah menunjukkan bahwa kNN dapat bekerja dengan sangat baik ketika data memiliki struktur yang sederhana. Di sisi lain, Wine Dataset yang memiliki lebih banyak fitur menunjukkan bahwa kNN dapat mengalami kesulitan dalam menangani dataset dengan dimensi yang lebih tinggi dan potensi overlap antar kelas. Ini mungkin disebabkan oleh fakta bahwa kNN tidak melakukan pemrosesan fitur yang kompleks dan sangat bergantung pada metrik jarak yang dapat menjadi kurang efektif dalam ruang fitur yang lebih besar.

Selain itu, performa yang tinggi pada Breast Cancer Dataset meskipun jumlah fiturnya lebih banyak menunjukkan bahwa kNN masih dapat bekerja dengan baik pada data yang memiliki fitur yang informatif dan terstruktur dengan baik, meskipun kompleksitasnya lebih tinggi. Hal ini menegaskan bahwa selain

Dari hasil ini, kita bisa menyimpulkan bahwa kNN cenderung lebih cocok untuk dataset dengan fitur yang lebih sedikit dan kelas yang terpisah dengan jelas.

[NbConvertApp] Writing 4721370 bytes to IF540L_H_laporan_M01_00000077732_Reinhard Javera Maheswara.html

In [549... print("Test set score: {:.2f}".format(knn.score(X_test, y_test)))

- Simpulan perbandingan dataset

print("I certify that this is my own work.")

2024-09-01 22:09:27.528704

[NbConvertApp] WARNING | Alternative text is missing on 3 image(s).

Markdown basics https://markdown-guide.readthedocs.io/en/latest/basics.html#

- Iris Dataset: Terdiri dari 150 instance, 4 fitur, dan tiga kelas target. - Wine Dataset: Terdiri dari 178 instance, 13 fitur, dan tiga kelas target.

4. Hasil pemikiran dan observasi akhir dari kerja menurut mahasiswa:

- Iris Dataset: Terdiri dari 150 instance, 4 fitur, dan tiga kelas target. - Wine Dataset: Terdiri dari 178 instance, 13 fitur, dan tiga kelas target.

4. Hasil pemikiran dan observasi akhir dari kerja menurut mahasiswa:

- Breast Cancer Dataset: Terdiri dari 569 instance, 30 fitur, dan dua kelas target.

- Breast Cancer Dataset: Terdiri dari 569 instance, 30 fitur, dan dua kelas target.

• convert the generated html file to PDF using the online tool: https://www.sejda.com/html-to-pdf

myDate = datetime.datetime.now()

print("Name: \t{}".format(myName)) print("NIM: \t{}".format(myNIM))

I certify that this is my own work.

Name: Reinhard Javera Maheswara

choose the following settings:

Page size: One long page Page Orientation: auto Use print stylesheet

Submit your ipython notebook and PDF files

print("Time-stamp:\t{}".format(myDate))

print("Signed by:")

In [544... **from** sklearn.neighbors **import** KNeighborsClassifier knn = KNeighborsClassifier(n_neighbors=1)

KNeighborsClassifier

KNeighborsClassifier(n_neighbors=1)

In [547... X_new = np.array([[5, 2.9, 1, 0.2] + [0]*26])

prediction = knn.predict(X_new)

print("X_new.shape: {}".format(X_new.shape))

print("X_new.shape: {}".format(X_new.shape))

print("Prediction: {}".format(prediction))

print("Test set predictions:\n {}".format(y_pred))

In $[546... | X_{new} = np.array([[5, 2.9, 1, 0.2]])$

In [545... knn.fit(X_train, y_train)

X_new.shape: (1, 4)

X_new.shape: (1, 30) Prediction: [1]

In [548... y_pred = knn.predict(X_test)

Test set predictions:

Test set score: 0.92

Kesimpulan

In [550... # Footer

Signed by:

NIM: 77732

Time-stamp:

Next step:

In [561... output= """

Kesimpulan:

print(output)

Perbandingan dataset:

2. Hasil akurasi yang diberikan: - Iris Dataset: akurasi sebesar 97% - Wine Dataset: akurasi sebesar 76%

- Breast Cancer Dataset: akurasi sebesar 92%

3. Hasil perbandingan akurasi antar algoritma:

Kesimpulan:

1. Perbandingan dataset:

2. Hasil akurasi yang diberikan: - Iris Dataset: akurasi sebesar 97% - Wine Dataset: akurasi sebesar 76%

- Breast Cancer Dataset: akurasi sebesar 92%

3. Hasil perbandingan akurasi antar algoritma:

Predicted target: ['benign']

Out[545...

In [540... print("Target data: {}".format(breast_cancer_dataset['target']))

'mean concave points' 'mean symmetry' 'mean fractal dimension' 'radius error' 'texture error' 'perimeter error' 'area error' 'smoothness error' 'compactness error' 'concavity error'

print("Predicted target: {}".format(wine_dataset['target_names'][prediction]))

 $[0\ 1\ 1\ 0\ 1\ 1\ 0\ 2\ 1\ 1\ 0\ 1\ 0\ 1\ 0\ 1\ 0\ 1\ 1\ 1\ 1\ 2\ 2\ 0\ 0\ 2\ 0\ 0\ 2$

In [526... knn.fit(X_train, y_train)

In [527... X_new = np.random.rand(1, 13)

X_new.shape: (1, 13)

In [529... y_pred = knn.predict(X_test)

Test set predictions:

1 1 1 2 0 1 1 1]

Test set score: 0.76

.. _breast_cancer_dataset:

Data Set Characteristics:

Target: ['malignant' 'benign']

:Number of Instances: 569

:Number of Attri

Shape: (569, 30)

Type: <class 'numpy.ndarray'>

4.601e-01 1.189e-01]

2.750e-01 8.902e-02]

3.613e-01 8.758e-02]

6.638e-01 1.730e-01]

2.364e-01 7.678e-02]]

Target shape: (569,)

1 1 1 1 1 1 1 0 0 0 0 0 0 1]

X_train shape: (426, 30) y_train shape: (426,) X_test shape: (143, 30) y_test shape: (143,)

In [541... | from sklearn.model_selection import train_test_split

print("y_train shape: {}".format(y_train.shape)) print("X_test shape: {}".format(X_test.shape)) print("y_test shape: {}".format(y_test.shape))

In [542... print("X_train shape: {}".format(X_train.shape))

Type of target: <class 'numpy.ndarray'>

Prediction: [1]

In [528... prediction = knn.predict(X_new)

Predicted target: ['class_1']

